

INDUSENSE · MAINTENANCE PRÉDICTIVE INDUSTRIELLE · CONFIDENTIEL

Modèle de Détection Anticipée de Défaillances Machines

Rapport de synthèse décisionnel — Résultats et recommandations

Auteur

Guillaume Saïdani

Date

Juillet 2026

Périmètre

15 machines · 132 940 observations · TP7-TP12

RÉSUMÉ EXÉCUTIF

- **Objectif atteint.** Le modèle détecte les défaillances 24 h à l'avance avec un score de performance de **0,88 / 1,0** sur des données jamais vues en entraînement.
- **Validation rigoureuse.** Le protocole de validation simule le déploiement réel : le modèle est évalué sur des machines qu'il n'a jamais observées pendant l'entraînement.
- **Déployable immédiatement sur 10 des 15 machines.** 4 machines donnent une détection quasi-parfaite ; 6 machines supplémentaires offrent de bonnes performances avec surveillance.
- **Fiabilité des résultats renforcée.** Une anomalie dans les données source a été identifiée et corrigée en cours de projet, éliminant un biais qui gonflait artificiellement les scores.

01

Contexte et enjeux

InduSense opère un parc de **15 machines industrielles** générant en continu des relevés de capteurs (pression, température, rotation, vibrations). Chaque heure, une fenêtre de données est consolidée et labellisée selon qu'une panne survient dans les 24 heures suivantes.

L'enjeu opérationnel est double : **anticiper les pannes** pour planifier des interventions préventives et **éviter les fausses alertes** qui mobilisent les techniciens inutilement. La forte rareté des événements de panne — 3,6 % des fenêtres seulement — rend la tâche techniquement exigeante et impose une métrique de performance adaptée.

OBSERVATIONS

132 940

fenêtres horaires

MACHINES

15

entités distinctes

TAUX DE PANNE

3,6 %

HORIZON

24 h

02

Données et protocole de validation

Source des données

Les données proviennent de la base **indusense_db**, table *gold_machine_hourly_feature*, enrichie de 69 indicateurs calculés par fenêtre horaire : agrégats statistiques des capteurs, compteurs d'incidents antérieurs, indicateurs de sévérité.

Une anomalie détectée et corrigée

En cours de projet, un identifiant technique (*feature_row_id*) a été identifié comme corrélé artificiellement aux événements de panne. Sa présence gonflait les scores de performance de 9 points de manière trompeuse. Il a été exclu définitivement : **tous les résultats présentés dans ce rapport sont calculés sans cet identifiant** et reflètent la performance réelle du modèle.

Protocole de validation orienté déploiement réel

La validation a été conduite en deux phases progressives :

Phase	Méthode	Ce qu'elle mesure
Phase 1	Découpage temporel (train / test)	Performance sur données futures, mêmes machines
Phase 2 — retenue	Validation machine par machine (GroupKFold)	Performance sur une machine jamais vue en entraînement

La phase 2 reproduit fidèlement le scénario de production : le modèle rencontre des machines dont il n'a aucune connaissance préalable. C'est le seul protocole qui garantit que les performances mesurées sont transposables en conditions réelles.


03

Performance du modèle

Indicateur de référence : le score de précision-rappel

Le score retenu (PR-AUC, compris entre 0 et 1) mesure simultanément la capacité du modèle à **détecter les pannes réelles** et à **limiter les fausses alertes**. Un score proche de 1 signifie que le modèle détecte la quasi-totalité des pannes sans surcharger les équipes d'interventions inutiles.

Progression au fil du développement





Étape	Score test	Protocole	Signification
Baseline après correction	—	Split temporel	Point de départ honnête
Après optimisation automatique	0,823	Split temporel	HP calibrés sur l'historique
Validation inter-machine	0,860	Machine par machine	Première mesure réaliste
Modèle final retenu (B11-GKF)	0,880	Machine par machine	Optimisé pour la généralisation

Le gain entre la première validation inter-machine (0,860) et le modèle final (0,880) provient d'un ré-étalonnage des paramètres du modèle en utilisant directement la validation inter-machine comme critère d'optimisation — garantissant une cohérence totale entre la méthode d'optimisation et le scénario de déploiement.

04

Modèle retenu et maturité par machine

Caractéristiques du modèle

Le modèle retenu est un **XGBoost** (algorithme d'apprentissage par gradient sur arbres de décision), optimisé par recherche bayésienne automatique (Optuna, 30 essais × 5 validations croisées). Il a été entraîné sur 3 ans de données de 15 machines et validé sur la capacité à détecter des pannes de machines non vues en entraînement.

SCORE TEST GLOBAL

0,880

sur données jamais vues

SCORE MOYEN INTER-MACHINE

0,784

CV 15 folds ± 0,19

F1-SCORE

0,759

seuil par défaut 0,5

Maturité de déploiement par machine

La validation machine par machine révèle quatre niveaux de maturité opérationnelle :

PRÊTES AU DÉPLOIEMENT (4 MACHINES)

MACH-15, MACH-11, MACH-08, MACH-06

Score individuel > 0,90 — signal sensoriel clair et répétable

DÉPLOYABLES AVEC SURVEILLANCE (6 MACHINES)

MACH-01, MACH-04, MACH-14

MACH-09, MACH-12, MACH-10

Score 0,76–0,88 — bonnes performances, revue mensuelle des alertes recommandée

COLLECTE ADDITIONNELLE REQUISE (4 MACHINES)

MACH-03, MACH-02, MACH-13, MACH-05

Score < 0,70 — hétérogénéité des comportements, données historiques insuffisantes

CAS PARTICULIER À TRAITER MANUELLEMENT (1 MACHINE)

MACH-07

Score bas lié à une dégradation tardive non représentée dans les données d'entraînement — 93 % des pannes sont néanmoins détectées une fois le signal présent

05

Conclusions

Le développement a permis de construire un modèle de détection anticipée de défaillances fiable et validé dans des conditions proches du déploiement réel. Trois conclusions principales se dégagent :

- 1. Le modèle est opérationnel pour 10 des 15 machines.** Les 4 machines « prêtes » peuvent bénéficier immédiatement d'alertes automatiques à 24 h. Les 6 machines « surveillées » peuvent être intégrées dans un second temps, avec un dispositif de contrôle de qualité des alertes pendant les premiers mois.
- 2. La rigueur méthodologique est un actif.** L'identification et la correction de la fuite de données, la validation machine par machine, et l'alignement entre le critère d'optimisation et le scénario de déploiement garantissent que le score de 0,88 est reproductible en production — et non un artefact de laboratoire.
- 3. Les 5 machines restantes ne sont pas un échec — elles nécessitent plus de données.** MACH-07 détecte 93 % de ses pannes mais manque d'historique de dégradation en phase précoce. Les 4 machines « collecte requise » présentent des comportements atypiques qui demandent un suivi spécifique, pas un modèle différent.

RECOMMANDATION

Lancer un pilote de 3 mois sur les 4 machines prêtes au déploiement (MACH-15, MACH-11,