

Détection anticipée de défaillances machines par apprentissage supervisé

Approche XGBoost avec validation GroupKFold et optimisation bayésienne — TP7 à TP12

Guillaume Saïdani guillaume.saidani@ext.aelion.fr Juillet 2026

TABLE DES MATIÈRES

- | | |
|------------------------------|--|
| 1. Contexte et objectif | 2. Données et features |
| 3. Méthodologie d'évaluation | 4. Résultats — progression des modèles |
| 5. Choix du modèle final | 6. Réglage du seuil de décision |
| 7. Pistes d'amélioration | 8. Conclusion |

01

Contexte et objectif

InduSense opère un parc de 15 machines industrielles instrumentées avec des capteurs IoT.

Les relevés sont agrégés en fenêtres horaires et stockés dans la table

`gold_machine_hourly_feature` de la base `indusense_db`. Chaque fenêtre est labellisée `label_failure_next_24h = 1` si une défaillance survient dans les 24 heures suivantes.

L'objectif est d'anticiper les pannes suffisamment tôt pour déclencher une maintenance préventive, réduire les arrêts non planifiés et optimiser les tournées de techniciens. La contrainte principale est le fort déséquilibre de classes : seulement 3,6 % des fenêtres précèdent une défaillance.

OBSERVATIONS

132 940

fenêtres horaires

MACHINES

15

entités distinctes

TAUX DE PANNE

3,6 %

déséquilibre 1 : 26

HORIZON

24 h

prédiction anticipée

02

Données et features

La table source contient 75 colonnes. Après exclusion des métadonnées et colonnes cibles alternatives, **69 features** ont été retenues — dont des agrégats statistiques par fenêtre (min, max, mean, std) sur les capteurs de pression, température, vibration et débit.

Découverte d'une fuite de données (TP8b)

Fuite détectée — `feature_row_id`

Cet identifiant séquentiel est fortement corrélé à `window_start`, lui-même corrélé aux périodes de dégradation. Inclus dans B5 et B7 (TP7), il produisait des modèles artificiellement performants (PR-AUC val $\approx$ 0,92). Retiré dès TP8b — toutes les métriques à partir de B5c sont honnêtes.

Split temporel — partitions

Partition	Observations	Positifs	Taux	Période
Train	93 079	3 474	3,7 %	Chronologiquement premier
Validation	19 917	773	3,9 %	Après train
Test	19 944	727	3,6 %	Chronologiquement dernier

Le champ `split_set` encode la partition. Aucune observation de val ou test n'est visible en train, garantissant l'absence de fuite temporelle (hors `feature_row_id`, identifiée et corrigée).

Déséquilibre de classes

Avec 3,6 % de positifs, le ratio est de 1 : 26. La pondération `scale_pos_weight` = 26,78 est appliquée à XGBoost pour compenser ce déséquilibre lors de l'apprentissage. En validation GroupKFold, ce paramètre est recalculé fold par fold pour refléter la composition réelle de chaque sous-ensemble d'entraînement.

03

Méthodologie d'évaluation

Métrique principale : PR-AUC

La courbe précision-rappel (Average Precision / PR-AUC) est la métrique de référence pour les problèmes à classes fortement déséquilibrées. Elle mesure la capacité du modèle à détecter les pannes (rappel) sans déclencher trop d'alertes inutiles (précision). Contrairement au ROC-AUC, elle n'est pas gonflée par la masse de vrais négatifs.

Deux phases de validation progressives

Phase	Protocole	Question	Limite
Phase 1 — TP7, TP8	Split temporel train / val / test	Le modèle prédit-il bien sur la période future ?	Toutes les machines sont dans train <i>et</i> val
Phase 2 — TP9, TP11	GroupKFold(15) — une machine par fold	Le modèle généralise-t-il à une machine <i>jamaïs vue</i> ?	Variance inter-machine élevée ($\sigma \approx 0,18$)

Pourquoi GroupKFold est nécessaire


Un modèle déployé en production rencontre régulièrement des machines nouvelles ou peu vues en entraînement. Le split temporel — où toutes les machines apparaissent en train et en val — ne teste pas ce scénario. GroupKFold exclut une machine entière à chaque fold et mesure réellement la capacité de généralisation inter-machine.

Pipeline de traitement

Chaque modèle suit le pipeline : `SimpleImputer(median)` → `XGBClassifier`. L'imputation est systématiquement fitée sur le train uniquement, puis appliquée à val et test. XGBoost gère nativement les valeurs manquantes restantes.

04

Résultats — Progression des modèles



Val/CV Test

Modèle	TP	PR-AUC val / CV	PR-AUC test	Statut
B5	TP7	~0,87	—	Fuite feature_row_id
B7	TP7	0,9213	—	Fuite + Optuna biaisé
B5c	TP8b	0,8349	—	Baseline honnête après correction
B7c	TP8b	0,8340	—	Optuna sur split temporel (HP biaisés)
B8	TP8b	0,8497	0,8232	Meilleurs HP sur split temporel
B8-ES	TP8c	0,8471	0,7968	Early stopping — régression test
B9-GKF	TP9	0,7792 ± 0,18	0,8595	GroupKFold, HP B8 réutilisés
B10-NRM	TP10	0,5580 ± 0,23	—	Normalisation — décalage domaine
B11-GKF	TP11	0,7839 ± 0,19	0,8799	Meilleur — Optuna GroupKFold
B12-GKF	TP12	0,7480 ± 0,23	0,8487	Stack 136 features — HP désalignés

Analyse des résultats intermédiaires

Correction de la fuite (TP8b) : la chute apparente de 0,92 → 0,83 reflète la réalité, pas une dégradation du modèle. B5 et B7 mesuraient la capacité à mémoriser un identifiant séquentiel, pas à prédire des pannes.

Early stopping (TP8c) : l'arrêt anticipé réduit à 57 arbres (au lieu de 382) mais l'overfitting persiste ($\Delta = 0,1529$ vs $0,1503$). Le score test recule à 0,7968. L'overfitting est structurel — les signatures de chaque machine sont mémorisées — et ne se corrige pas par le seul early stopping.

Normalisation intra-machine (TP10) : tentative de z-score par machine avant l'entraînement. Résultat : CV = 0,5580, effondrement de 22 points. Cause identifiée : la machine de validation n'a pas de statistiques propres calculables — elle reçoit les z-scores flotte, créant un décalage de domaine entre train et val. Expérience négative documentée ; la règle retenue est de normaliser au niveau feature engineering (pré-calculé en base), pas à l'entraînement.

Z-score machine pré-calculé — stratégie Stack (TP12) : pré-calcul des z-scores sur l'historique complet machine (correction du domain shift de TP10) puis empilement des 67 nouvelles features sur les 67 raw → 136 features. Résultat : CV = 0,7480, régression de -0,031 vs B11. Diagnostic : 136 features, 0,574 exposé décalage, 59 features / arbre au lieu de

vs B11. Diagnostic : colsample_bytree = 0,574 expose des outliers ~70 features/ arbre au lieu de ~40 — les paires corrélées (raw + zmachine) diluent le signal. Les HP B11 sont désalignés avec un espace de 136 features. La stratégie *Replace* (remplacer raw par zmachine, N stable à 69) reste à tester.

05

Choix du modèle final

Le modèle **B11-GKF** est retenu : XGBoost optimisé par Optuna (30 trials × 5 folds GroupKFold), avec évaluation finale sur 15 folds (une machine par fold). C'est le seul modèle dont les hyperparamètres ont été optimisés en visant directement la généralisation à de nouvelles machines.

PR-AUC TEST

0,8799

meilleur de la série

PR-AUC CV

0,7839

± 0,1891 — 15 folds

F1 TEST

0,7586

seuil 0,5

OVERFITTING Δ

0,216

train=0,9997 vs CV

Fingerprint hyperparamétrique — B8 vs B11

La comparaison des hyperparamètres révèle l'impact du critère d'optimisation. B8 était optimisé sur le split temporel (mêmes machines en train et val) → favorise la mémorisation. B11 optimisé sur GroupKFold → force la régularisation.

Hyperparamètre	B8 — split temporel	B11 — GroupKFold	Ratio
n_estimators	382	287	↓ 25 %
max_depth	8	9	↑
learning_rate	0,1937	0,0289	÷ 7
subsample	0,987	0,825	↓
colsample_bytree	0,804	0,574	↓↓
min_child_weight	6	11	↑↑
reg_alpha	0,00144	0,0192	× 13
reg_lambda	0,000142	0,623	× 4 380

reg_lambda quasi nul en B8 (la mémorisation des machines était tolérée par le critère d'optimisation) vs 0,623 en B11 (la régularisation est imposée par le signal GroupKFold). Ce ratio $\times 4\,380$ confirme l'hypothèse : B8 avait été tuné autour de la mémorisation machine, pas de la généralisation.

Performance par machine — B9-GKF vs B11-GKF

Machine	B9-GKF	B11-GKF	Δ	Profil
MACH-15	1,000	1,000	=	Fiable
MACH-11	1,000	1,000	=	Fiable
MACH-08	0,955	1,000	+0,045	Fiable
MACH-06	0,917	0,947	+0,030	Fiable
MACH-01	0,878	0,936	+0,058	Fragile
MACH-04	0,874	—	—	Fragile
MACH-14	0,793	—	—	Fragile
MACH-09	0,784	—	—	Fragile
MACH-12	0,761	—	—	Fragile
MACH-10	0,760	—	—	Fragile
MACH-03	0,707	—	—	Problématique
MACH-02	0,664	0,449	-0,215	Problématique
MACH-13	0,639	—	—	Problématique
MACH-05	0,568	—	—	Problématique
MACH-07	0,329	0,387	+0,058	Artefact temporel

Segmentation opérationnelle

FIABLES (> 0,90)

MACH-15, MACH-11
MACH-08, MACH-06

Détection quasi-parfaite — signal sensoriel clair

FRAGILES (0,70–0,90)

MACH-01, MACH-04
MACH-14, MACH-09
MACH-12, MACH-10

Bonnes performances, vigilance conseillée

PROBLÉMATIQUES (< 0,70)

MACH-03, MACH-02
MACH-13, MACH-05

Hétérogénéité sensorielle — feature engineering ciblé

ARTEFACT TEMPOREL

MACH-07

0,8 % de pannes en train vs 3,5 %
en val — dégradation tardive (H1
confirmée)

Analyse MACH-07 — PR-AUC = 0,329

H1 confirmée — Artefact temporel, pas un échec du modèle

MACH-07 présente 0,8 % de pannes en période d'entraînement contre 3,5 % en validation (dégradation tardive, non représentée en train). Le modèle n'a jamais observé de pannes en conditions nominales pour cette machine. H2 (profil sensoriel atypique) est rejetée : seulement 3 features présentent $|z| > 2$ vs flotte. H3 (incapacité à scorer les pannes) est rejetée : 93 % des pannes de MACH-07 sont scorées $> 0,5$ quand on applique le modèle. Le PR-AUC bas (0,329 / 0,387) est un artefact statistique dû aux 24 positifs seulement en val.

06

Réglage du seuil de décision

Le seuil par défaut (0,5) n'est pas optimal pour la maintenance prédictive. Les coûts sont asymétriques :

Erreur	Conséquence opérationnelle	Coût
Faux négatif (FN)	Panne non détectée → arrêt non planifié, production perdue	Élevé
Faux positif (FP)	Intervention préventive inutile → coût technicien	Modéré

Un seuil plus bas (0,30–0,40) favorise le rappel au détriment de la précision, ce qui est généralement préféré. Le modèle B11-GKF atteint **F1 = 0,7586** au seuil 0,5. Le seuil optimal doit être calibré avec les équipes opérationnelles en fonction du ratio coût FN / coût FP propre au contexte client.

Une étape de calibration des probabilités (Platt scaling, régression isotonique) permettrait d'aligner les scores de sortie sur les fréquences réelles de panne et de rendre le réglage du seuil plus interprétable.

07

Pistes d'amélioration

Ce qui a été implémenté

- ✓ **Correction de la fuite `feature_row_id` (TP8b)**
Identifiée et exclue — toutes les métriques TP8b → TP11 sont honnêtes
- ✓ **GroupKFold par machine — validation honnête (TP9)**
15 folds, une machine exclue par fold — score CV reproductible et interprétable par entité
- ✓ **Diagnostic per-machine — analyse H1/H2/H3 (TP9 §6)**
MACH-07 disséqué : artefact temporel identifié, segmentation Fiable / Fragile / Problématique construite
- ✓ **Normalisation intra-machine expérimentée et documentée (TP10)**
CV = 0,5580 — échec documenté ; règle dégagée : normaliser au niveau feature engineering, pas entraînement
- ✓ **Optuna GroupKFold comme objectif (TP11)**
HP re-tunés directement sur la généralisation machine — fingerprint radicalement différent de B8 ($\text{reg_lambda} \times 4380$)
- ✓ **Z-score machine pré-calculé — stratégie Stack expérimentée (TP12)**
CV = 0,7480 — concept juste (stats sur historique complet), implémentation à affiner : empilement $69+67=136$ features désaligne `colsample_bytree`

Ce qui reste à faire

- ✗ **Z-score machine — stratégie *Replace* (B12b) — non retenu**
XGBoost invariant à l'échelle (seuils, pas distances) · zmachine critiques (temp, pressure) déjà dans B11 · features count z-scorées perdent leur sens absolu → abandon confirmé
- **Calibration des probabilités**
Platt scaling ou régression isotonique — aligner les scores sur les fréquences réelles pour un réglage de seuil plus interprétable
- **Feature engineering ciblé sur machines Problématiques**
MACH-02, MACH-03, MACH-05, MACH-13 présentent une hétérogénéité sensorielle — explorer des lags temporels ou des combinaisons non linéaires de capteurs
- **Stratégie de burn-in pour machines nouvelles**
En production : utiliser les stats flotte les premières semaines, basculer vers les stats machine dès N observations disponibles

Conclusion

L'objectif — prédire les défaillances machines à 24 h avec un PR-AUC supérieur à 0,85 sur données test — est atteint avec le modèle **B11-GKF** (PR-AUC test = **0,8799**), meilleur résultat de la série de TP7 à TP12.

Le chemin parcouru a mis en évidence trois enseignements principaux :

1. **Le protocole de validation définit la signification du score.** Un PR-AUC de 0,92